Разработка стратегии, оценка рисков и дорожной карты AI-проекта «Интеллектуальная система рекомендаций»

1. Уточняющие вопросы клиенту

1. Какие исторические данные о поведении пользователей доступны и за какой период?

Для обучения рекомендаций нужны просмотры, клики, корзины и покупки. Сейчас сырые логи почти не хранятся, поэтому важно понять, можно ли выгрузить историю из Google Analytics и быстро настроить собственный event-трекинг.

2. Как связаны онлайн- и офлайн-покупки одного клиента?

Нужно понять, есть ли единый идентификатор: карта лояльности, телефон или другой ID. Без этого требование омниканальности реализовать полностью нельзя.

3. Какие ограничения действуют на обработку персональных данных?

Нужно определить, разрешено ли использовать российское облако или требуется on-prem/private cloud. ПДн не должны передаваться в публичные LLM.

4. Что именно означает требование времени ответа 200 мс?

Нужно уточнить, относится ли оно только к API рекомендаций или ко всей загрузке блока. LLM-описания, скорее всего, потребуется генерировать заранее, а не в реальном времени.

5. Какие изменения допустимы в Bitrix?

CTO не хочет менять ядро. Нужно подтвердить возможность подключить отдельный рекомендательный сервис через API и асинхронный виджет.

6. Кто будет сопровождать AI-систему после запуска?

У клиента нет Data Scientists и Data Engineers. Нужно понять, будет ли формироваться внутренняя команда или сопровождение останется у интегратора.

7. Какие метрики будут считаться успехом проекта?

Нужно заранее зафиксировать целевые показатели: конверсию блока рекомендаций, CTR, средний чек и допустимую задержку. Иначе невозможно сформировать объективные критерии приемки.

2. Выбор контрактной модели

Для всего проекта Fixed Price не подходит: на старте неизвестно качество данных и нельзя заранее гарантировать качество ML-модели. Поэтому контрактную модель лучше менять по мере снижения неопределенности.

Этап	Контракт	Почему
PoC	T&M	Максимальная неопределенность. Оплачивается исследование и проверка гипотезы, а не заранее обещанный результат.
MVP	T&M with a cap	После PoC scope понятнее, но

		итерации еще нужны. Заказчик получает верхнюю границу бюджета, команда сохраняет гибкость.
Production	Fixed Price / SLA	Технология и требования уже проверены. Конкретные работы и показатели надежности можно зафиксировать.

Выгода для заказчика: он не берет на себя стоимость большого проекта до проверки гипотезы и получает контроль бюджета. Выгода для интегратора: команда не обязана закладывать большой риск в Fixed Price и может корректировать решение по результатам экспериментов.

3. Матрица рисков

Для количественной оценки используется подход из шаблона реестра рисков: для каждого риска задаются вероятность наступления и три оценки ущерба (минимальная, ожидаемая и максимальная). В качестве простой единицы ущерба для данного учебного проекта используются рабочие дни дополнительной работы/задержки.

№	Риск	Вероятность	Размер ущерба, раб. дней			Ожидаемый риск	Лимит	Митигация
			Мин.	Ожид.	Макс.	P × ожид.	раб. дней	
R1	Недостаток / низкое качество данных	70%	5	15	30	10.5	10	Data discovery; выгрузка истории; event tracking; fallback.
R2	Утечка ПДн через LLM	20%	5	20	40	4.0	5	Обезличивание; private cloud/on-prem; аудит логов.
R3	Latency выше 200 мс	60%	3	10	20	6.0	7	Precompute LLM; кэш; нагрузочные тесты; контроль p95.
R4	Галлюцинации LLM	40%	3	8	15	3.2	5	Каталог как источник фактов; guardrails; проверка текстов.
R5	Деградация модели / data drift	40%	2	7	14	2.8	5	Мониторинг метрик; retraining; A/B-тест новых версий.
R6	Проблемы интеграции с Bitrix	35%	5	12	25	4.2	7	Отдельный сервис; API; кэш; без изменений ядра Bitrix.

Ожидаемый риск = вероятность наступления × ожидаемый ущерб. Лимит показывает допустимый для проекта уровень дополнительной задержки. Оценки являются экспертными и нужны для приоритизации рисков, а не как точный прогноз.

4. Roadmap

Этап	Срок	Что делаем	Результат	Definition of Done
PoC	1-4 недели	Аудит данных;	Отчет об	Есть данные для

		baseline; прототип ML-рекомендаций; проверка LLM-описаний; замер latency.	эксперименте и решение GO/NO-GO.	обучения; ML лучше текущего baseline по согласованной offline-метрике; LLM работает без передачи ПДн; понятны риски и оценка MVP.
MVP	5-12 недели	Отдельный recommendation API; интеграция с Bitrix; сбор событий; кэш; A/B-тест на части трафика.	Работающий пилот на реальных пользователях.	A/B-тест показывает статистически значимое улучшение согласованной бизнес-метрики; p95 <= 200 мс; нет утечки ПДн; есть fallback на rule-based рекомендации.
Production	После 3 месяцев	Масштабирование; CI/CD; мониторинг; retraining; омниканальность; персонализация главной и рассылок.	Промышленная рекомендательная система.	SLA согласован и соблюдается; мониторинг и алерты работают; модель переобучается; подтвержден бизнес-эффект; есть документация и процесс сопровождения.

Итог

Стратегия проекта: не пытаться сразу построить «как у Ozon», а последовательно снижать неопределенность. За первые 3 месяца нужно проверить данные и модель, затем вывести MVP на ограниченную аудиторию и получить измеримый результат A/B-теста. После подтверждения бизнес-эффекта систему можно масштабировать до Production.